

Shouth NLP en SemEval-2025 Tarea 7: Retrieval Multilingüe para Fact-Checking Usando Contrastive Learning

Santiago Lares Harbin and Juan Manuel Pérez

Universidad de San Andrés
slaresharbin@udesa.edu.ar

Resumen

Presentamos un sistema de retrieval multilingüe para fact-checking en la tarea de SemEval-2025, cuyo objetivo es emparejar publicaciones de redes sociales con fact-checks relevantes. Nuestro enfoque utiliza un framework de contrastive learning construido sobre la arquitectura del modelo multilingüe E5, fine-tuned con el dataset provisto. El sistema alcanza un puntaje Success@10 de 0.867 en el conjunto de test oficial, con variaciones de rendimiento entre idiomas. Demostramos que los prefixes de entrada y el filtrado del corpus por idioma mejoran significativamente el rendimiento del retrieval. Nuestro análisis revela patrones interesantes en la transferencia cross-lingual, con resultados particularmente buenos en malayo y tailandés. Hacemos público nuestro código para futuras investigaciones y desarrollos.

1. Introducción

La proliferación de desinformación en redes sociales es referida por científicos sociales como una amenaza a la integridad de la democracia y la esfera pública (Chambers, 2021; Lewandowsky et al., 2023). Este escenario ha generado una necesidad urgente de sistemas automatizados de fact-checking capaces de recuperar fact-checks relevantes para claims dudosos. La Tarea de SemEval-2025 (Shahi et al., 2025) aborda este desafío requiriendo que los participantes desarrollen sistemas que puedan recuperar los fact-checks más relevantes para publicaciones de redes sociales de un corpus extenso de 272,447 fact-checks en múltiples idiomas.

En este trabajo, presentamos nuestro enfoque para esta tarea, que utiliza un modelo de embeddings multilingüe fine-tuned basado en la arquitectura E5 (Wang et al., 2024). Nuestro sistema emplea un framework de contrastive learning para optimizar el matching semántico entre publicaciones y fact-checks durante el fine-tuning. Nos enfocamos particularmente en el aprendizaje de representa-

ciones multilingües y las funciones de retrieval cross-lingual. El código de nuestro sistema está disponible públicamente en GitHub¹.

Nuestras principales contribuciones incluyen: (1) un análisis de varias arquitecturas de modelos y su rendimiento entre diferentes idiomas, (2) un examen de cómo los prefixes de entrada afectan la precisión del retrieval, y (3) una demostración de la importancia del filtrado del corpus por idioma para mejorar el rendimiento del retrieval. Nuestro sistema alcanzó un puntaje promedio Success@10 de 0.867 en el conjunto de test oficial, ubicándose en el puesto 20 de 28 participantes publicados.

2. Antecedentes

El fact-checking automatizado ha emergido como una herramienta crítica en el combate contra la propagación de desinformación en línea. (Zhou and Zafarani, 2020) hablan sobre el inmenso volumen de información compartida en línea, y sugieren y evalúan diferentes métodos para detectar noticias falsas. La Tarea de SemEval-2025 (Peng et al., 2025) se enfoca especialmente en el retrieval de fact-checks multilingüe, donde el objetivo es emparejar publicaciones de redes sociales con fact-checks relevantes de un extenso corpus multilingüe. La mayoría de los sistemas automatizados de fact-checking consisten en tres pasos (Guo et al., 2022): primero, la detección del claim (¿es esto verificable?); luego, el retrieval de evidencia (dado un claim, recuperar información relevante para verificarlo); y por último, la verificación del claim (dado un claim y evidencia, definir si el claim es verdadero o falso).

La tarea (Peng et al., 2025) tiene dos subtareas: retrieval monolingüe y retrieval cross-lingual. Nosotros nos enfocamos únicamente en la subtarea monolingüe.

Los avances recientes en modelos de embed-

¹https://github.com/sanlares/semeval_2025

dings multilingües han mostrado resultados prometedores para tareas de retrieval multilingüe (Feng et al., 2022; Litschko et al., 2022). Estos modelos aprenden un espacio semántico compartido entre idiomas, permitiendo la comparación efectiva de texto independientemente del idioma de origen. En particular, los enfoques de contrastive learning han demostrado ser efectivos para entrenar tales modelos (Chen et al., 2020), ya que optimizan explícitamente la similitud entre textos relacionados mientras alejan los textos no relacionados en el espacio de embeddings. En este trabajo, presentamos nuestro enfoque de retrieval para esta tarea, que usa un modelo de embeddings multilingüe fine-tuned basado en la arquitectura E5 (Wang et al., 2024). Este modelo ha demostrado un rendimiento sólido en benchmarks de retrieval multilingüe (Zhang et al., 2021) al combinar encoders basados en transformer con pre-training contrastivo. Adicionalmente, hacemos fine-tuning de este modelo con los datos específicos de la tarea para mejorar su rendimiento en el retrieval de fact-checks.

3. Descripción del Sistema

Nuestro sistema aborda el desafío de recuperar fact-checks relevantes de un extenso corpus de 272,447 documentos implementando un enfoque de contrastive learning fine-tuned basado en la arquitectura del modelo multilingüe E5. El sistema consiste en tres componentes principales: (1) un modelo de embeddings de texto, (2) un framework de contrastive learning, y (3) un pipeline de retrieval.

El núcleo de nuestro sistema está construido sobre el Modelo Multilingüe E5 (Wang et al., 2024), que mejoramos con una arquitectura personalizada. La arquitectura del modelo se ilustra en la Figura 1, consistiendo en un encoder transformer, una capa de mean pooling, una capa de proyección densa con activación GELU, y normalización L2 para el cálculo de similitud coseno.

El modelo procesa tanto publicaciones como fact-checks usando prefixes específicos por idioma (query: y passage: respectivamente) para optimizar el matching semántico entre ellos.

Entrenamos nuestro modelo usando la Multiple Negatives Ranking Loss (MNRL) (Jadwin and Huang, 2023), que puede formularse como:

$$L = -\log \frac{\exp(\text{sim}(x_i, x_i^+)/\tau)}{\sum_{j=1}^N \exp(\text{sim}(x_i, x_j)/\tau)} \quad (1)$$




Figura 1: Arquitectura del modelo de embeddings usado en nuestro sistema. El modelo procesa tanto publicaciones como fact-checks usando prefixes específicos por idioma para optimizar el matching semántico.

donde:

- x_i representa el embedding del texto ancla (publicación)
- x_i^+ representa el embedding del par positivo (fact-check correspondiente)
- x_j representa todas las otras muestras en el batch (pares negativos)
- τ es un parámetro de temperatura que controla la nitidez de la distribución
- $\text{sim}(\cdot, \cdot)$ es la función de similitud coseno

Usamos negativos in-batch para eficiencia computacional mientras mantenemos un contrastive learning efectivo. El parámetro de temperatura τ se ajusta dinámicamente durante el entrenamiento para optimizar el proceso de aprendizaje.

El proceso de retrieval sigue estos pasos:

1. **Detección de Idioma:** El sistema primero identifica el idioma de la publicación de entrada.
2. **Filtrado del Corpus:** El corpus de fact-checks se filtra para priorizar documentos en

el mismo idioma que la publicación de entrada.

3. **Generación de Embeddings:** El modelo genera embeddings tanto para la publicación de entrada como para los fact-checks filtrados.
4. **Ranking por Similitud:** El sistema computa la similitud coseno de Pearson entre los embeddings de la publicación y los fact-checks.
5. **Selección Top-K:** Se recuperan y ordenan los 10 fact-checks más similares.

Este pipeline está configurado tanto para retrieval monolingüe como cross-lingual, con consideración especial para las distinciones específicas por idioma en el espacio de embeddings.

4. Configuración Experimental

4.1. Dataset

El dataset utilizado para este estudio fue derivado de los datos oficiales de la competencia SemEval-2025. Dividimos el conjunto de entrenamiento en subconjuntos de entrenamiento (80 %) y validación (20 %) mientras manteníamos la distribución de idiomas para ambos conjuntos.

Para el preprocesamiento, utilizamos el archivo `load.py` recomendado por los organizadores de la competencia. Nuestro enfoque involucró la creación de representaciones semánticas tanto para publicaciones como para fact-checks. Para las publicaciones, concatenamos el texto extraído por OCR (columna `ocr`) con la transcripción manual (columna `text`) del archivo `posts.csv`. De manera similar, para los fact-checks, combinamos las columnas `claim` y `title` del archivo `fact_checks.csv`. Para la entrada del modelo, se antepusieron prefixes relevantes (por ejemplo, `query:`, `passage:`) a estos textos concatenados antes de la tokenización para guiar la comprensión contextual del modelo.

Además de hacer fine-tuning de nuestro modelo principal, realizamos experimentos con varios modelos base disponibles en el framework SentenceTransformers, probando diferentes combinaciones de prefixes que arrojaron resultados de rendimiento variados.

4.2. Detalles de Implementación

El sistema fue implementado usando la siguiente configuración:

- **Modelo Base:** multilingual-e5-large-instruct

- **Framework:** SentenceTransformers (v3.4.1)
- **Backend de Deep Learning:** PyTorch (v2.5.1)
- **Versión de Python:** 3.12.7
- **Entorno de Cómputo:** macOS 15.1 (24B83)

El modelo fue entrenado con los siguientes hiperparámetros:

Parámetro	Valor
Longitud Máxima de Secuencia	512 tokens
Modo de Pooling	Mean
Dimensión de Embedding	384
Tamaño de Batch	4
Tamaño de Batch de Evaluación	16
Pasos de Acumulación de Gradiente	2
Learning Rate	2e-5
Temperatura	0.05
Entrenamiento con Precisión Mixta	Habilitado

Cuadro 1: Hiperparámetros de entrenamiento del modelo

La métrica principal de evaluación para nuestro sistema fue Success@10 (S@10), que mide la proporción de publicaciones para las cuales el fact-check correcto aparece en los 10 resultados principales recuperados. Evaluamos el rendimiento del modelo en configuraciones tanto monolingües como cross-lingual:

5. Resultados

Evaluamos el rendimiento de nuestro sistema en los conjuntos de validación y test, analizando el impacto de diferentes configuraciones del modelo y el rendimiento específico por idioma. Nuestro sistema alcanzó un puntaje promedio Success@10 de **0.867** en el conjunto de test oficial, ubicándose en el puesto 20 de 28 participantes publicados.

Los resultados demuestran una variabilidad considerable en el rendimiento del modelo entre idiomas, con malayo (`msa`) mostrando el mejor rendimiento con 0.978 e inglés (`eng`) y portugués (`por`) mostrando el más bajo con 0.796. Esta disparidad sugiere que factores lingüísticos pueden jugar un rol significativo en el rendimiento del retrieval.

La Tabla 3 muestra la comparación de rendimiento de diferentes modelos base y configuraciones de prefixes de entrada en el conjunto de validación. Los resultados demuestran que el modelo multilingual-e5-large-instruct con los prefixes apropiados supera consistentemente a otras configuraciones. El modelo base *intfloat/multilingual* –

Idioma	Success@10	Rendimiento Relativo
Malayo (msa)	0.978	+12.8 %
Tailandés (tha)	0.940	+8.4 %
Árabe (ara)	0.912	+5.2 %
Francés (fra)	0.894	+3.1 %
Español (spa)	0.866	-0.1 %
Alemán (deu)	0.858	-1.0 %
Turco (tur)	0.828	-4.5 %
Polaco (pol)	0.806	-7.0 %
Inglés (eng)	0.796	-8.2 %
Portugués (por)	0.796	-8.2 %
Promedio	0.867	—

Cuadro 2: Resultados oficiales del conjunto de test del modelo multilingual-e5-large-instruct fine-tuned por idioma. Los idiomas están ordenados por puntaje Success@10. El mejor rendimiento se muestra en **negrita**. El modelo muestra un rendimiento sólido en malayo y tailandés.

e5 – large – instruct (Wang et al., 2024) mejoró de un Success@10 promedio de 0.834 a 0.867 cuando se le hizo fine-tuning con el dataset de entrenamiento, junto con los prefixes recomendados de query y passage. Esta mejora fue consistente para todos los idiomas testeados en la competencia.

5.1. Impacto de los Prefixes de Entrada

Nuestros experimentos revelaron que la elección de prefixes de entrada impacta significativamente el rendimiento del modelo. Usar los prefixes recomendados en el modelo base multilingual-e5-large-instruct ('passage:' y 'query:') mejoró el puntaje promedio Success@10 en 0.013 puntos (de 0.821 a 0.834) comparado con no usar prefixes. Esta mejora fue consistente en todos los idiomas, con las mayores ganancias observadas en:

- Inglés: +0.022 (de 0.766 a 0.788)
- Español: +0.012 (de 0.857 a 0.869)
- Portugués: +0.018 (de 0.781 a 0.799)

Estos resultados sugieren que el formateo apropiado de la entrada juega un rol vital en mejorar la comprensión cross-lingual del modelo y las funciones de retrieval.

5.2. Análisis de Reducción del Corpus

Nuestros experimentos mostraron que el rendimiento mejora significativamente cuando el corpus de fact-checks se reduce en tamaño. Específicamente, cuando se usa solo el subconjunto de aproximadamente 16,000 fact-checks correspondientes al conjunto de validación (versus el corpus completo de 272,447), los puntajes de Success@10 mejoraron en un promedio de 10.2 %. Esta mejora demuestra el impacto del tamaño del corpus en la

precisión del retrieval. Para experimentos más detallados sobre reducción del corpus con el modelo fine-tuned, ver la Tabla 4 en el Apéndice A.

Nuestro análisis reveló varios resultados clave:

- El modelo base multilingual-e5-large-instruct supera consistentemente a otras opciones.
- La arquitectura de entrenamiento del modelo implementada es adecuada para el entrenamiento con el dataset provisto, permitiendo obtener un modelo fine-tuned que supera al mejor modelo base testado en los experimentos.
- Los prefixes de entrada apropiados pueden proporcionar ganancias de rendimiento sustanciales, mejorando Success@10 en 0.013 puntos en promedio.
- Existe una variabilidad considerable en el rendimiento del modelo entre idiomas, sugiriendo que el tuning específico por idioma podría generar mejoras adicionales.
- La reducción del corpus por idioma mejora dramáticamente la precisión del retrieval, destacando la importancia de estrategias efectivas de pre-filtrado.

El trabajo subsiguiente podría enfocarse en abordar la discrepancia de rendimiento entre idiomas, quizás a través de fine-tuning específico por idioma o técnicas más sofisticadas de transferencia cross-lingual. Además, explorar métodos de ensemble que combinen múltiples modelos de embeddings podría mejorar la precisión del retrieval para idiomas desafiantes.

Modelo Base	Prefix de Posts	Prefix de Facts	Success@10
multilingual-e5-large-instruct (Wang et al., 2024)	passage:	query:	0.834
multilingual-e5-large-instruct (Wang et al., 2024)	–	–	0.821
multilingual-e5-small (Wang et al., 2024)	–	–	0.795
e5-large-v2 (Wang et al., 2022)	–	–	0.758
modernbert-embed-base (Nussbaum et al., 2024)	search_query:	search_document:	0.779
paraphrase-multilingual-mpnet-base-v2 (Reimers and Gurevych, 2019)	–	–	0.736

Cuadro 3: Comparación de rendimiento de modelos base en el conjunto de validación. Los modelos están ordenados por puntaje Success@10. El mejor resultado se muestra en **negrita**.

6. Agradecimientos

Queremos agradecer a los organizadores de la tarea SemEval-2025 por crear esta tarea desafiante e impactante, y por proporcionar métricas de evaluación y datasets exhaustivos.

References

Simone Chambers. 2021. [Truth, deliberative democracy, and the virtues of accuracy: Is fake news destroying the public sphere?](#) *Political Studies*, 69(1):147–163.

Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. 2020. *A Simple Framework for Contrastive Learning of Visual Representations*, volume 119 of *PMLR*, pages 1597–1607. Virtual. Editors: Daumé, Hal and Singh, Aarti.

Fangxiaoyu Feng, Yinfei Yang, Daniel Cer, Naveen Arivazhagan, and Wei Wang. 2022. [Language-agnostic bert sentence embedding](#). *Preprint*, arXiv:2007.01852.

Zhijiang Guo, Michael Schlichtkrull, and Andreas Vlachos. 2022. A survey on automated fact-checking. *Transactions of the Association for Computational Linguistics*, 10:178–206.

Addison Jadwin and Catherine Huang. 2023. Improving minbert performance on multiple tasks through in-domain pretraining, negatives ranking loss learning, and hyperparameter optimization.

Stephan Lewandowsky, Ullrich K.H. Ecker, John Cook, Sander van der Linden, Jon Roozenbeek, and Naomi Oreskes. 2023. [Misinformation and the epistemic integrity of democracy](#). *Current Opinion in Psychology*, 54:101711.

Robert Litschko, Ivan Vulić, Simone Paolo Ponzetto, and Goran Glavaš. 2022. [On cross-lingual retrieval with multilingual text encoders](#). *Information Retrieval Journal*, 25(2):149–183.

Zach Nussbaum, John X. Morris, Brandon Duderstadt, and Andriy Mulyar. 2024. [Nomic embed: Training a reproducible long context text embedder](#). *Preprint*, arXiv:2402.01613.

Qiwei Peng, Robert Moro, Michal Gregor, Ivan Srba, Simon Ostermann, Marian Simko, Juraj Podroužek, Matúš Mesarčík, Jaroslav Kopčan, and Anders Søgaard. 2025. Semeval-2025 task 7: Multilingual and crosslingual fact-checked claim retrieval. In *Proceedings of the 19th International Workshop on Semantic Evaluation*, SemEval 2025, Vienna, Austria.

Nils Reimers and Iryna Gurevych. 2019. [Sentence-bert: Sentence embeddings using siamese bert-networks](#).

Gautam Kishore Shahi, Preslav Nakov, Giovanni Da San Martino, Wenjun Gao, Firoj Alam, Hamdy Mubarak, Arthur Brack, Ussama Yaqub, Bader Alshemali, Fahim Alam, Sara Mourad, Temitope Ndapa Nakashole, Tien Lahouasse, Oliver Kutz, Ralf Möller, and Kalina Bontcheva. 2025. Semeval-2025 task 1: Multilingual and cross-lingual fact-checking retrieval. In *Proceedings of the 19th International Workshop on Semantic Evaluation*. Association for Computational Linguistics.

Liang Wang, Nan Yang, Xiaolong Huang, Binxing Jiao, Linjun Yang, Daxin Jiang, Rangan Majumder, and Furu Wei. 2022. Text embeddings by weakly-supervised contrastive pre-training. *arXiv preprint arXiv:2212.03533*.

Liang Wang, Nan Yang, Xiaolong Huang, Linjun Yang, Rangan Majumder, and Furu Wei. 2024. Multilingual e5 text embeddings: A technical report. *arXiv preprint arXiv:2402.05672*.

Xinyu Zhang, Xueguang Ma, Peng Shi, and Jimmy Lin. 2021. [Mr. tydi: A multi-lingual benchmark for dense retrieval](#). *Preprint*, arXiv:2108.08787.

Xinyi Zhou and Reza Zafarani. 2020. [A survey of fake news: Fundamental theories, detection methods, and opportunities](#). *ACM Comput. Surv.*, 53(5).

A. Análisis de Reducción del Corpus

La Tabla 4 muestra el impacto de la reducción del corpus en el rendimiento del modelo fine-tuned. Los resultados demuestran que usar subconjuntos específicos por idioma del corpus de fact-checks

Modelo	Prefix Posts	de	Prefix Facts	de	S@10
multi-e5	query:		passage:		0.934
multi-e5	—		—		0.933
multi-e5	post:		fact check:		0.934
multi-e5	This is a		This is a fact...		0.936
	post...				
multi-e5	<[language]>		—		0.933
multi-e5	The follo-		The follo-		0.934
	wing...		wing...		

Cuadro 4: Rendimiento del modelo fine-tuned con diferentes configuraciones usando un corpus reducido. Todos los experimentos fueron realizados en el conjunto de validación con un corpus conteniendo solo fact-checks en el mismo idioma que las publicaciones de consulta, resultando en puntajes generales más altos comparados con la evaluación del corpus completo.

mejora significativamente el rendimiento del retrieval.

Nuestros experimentos mostraron que el rendimiento mejora significativamente cuando el corpus de fact-checks se reduce para incluir solo documentos en el mismo idioma que la publicación de consulta. Por ejemplo, cuando se recupera de un subconjunto específico por idioma de aproximadamente 16,000 fact-checks (versus el corpus completo de 272,447), los puntajes de Success@10 mejoraron en un promedio de 10.2 %.